Modelo Cardíaco

Previsão da doença cardíaca
com aprendizado de máquina.

Introdução

Este projeto analisa uma base de dados com 270 pacientes com 12 variáveis para prever a presença de doença cardíaca. Foram removidas variáveis com baixa correlação e aplicados três modelos de aprendizado de máquina, buscando o melhor desempenho preditivo por meio de ajuste de hiperparâmetros e validação rigorosa.

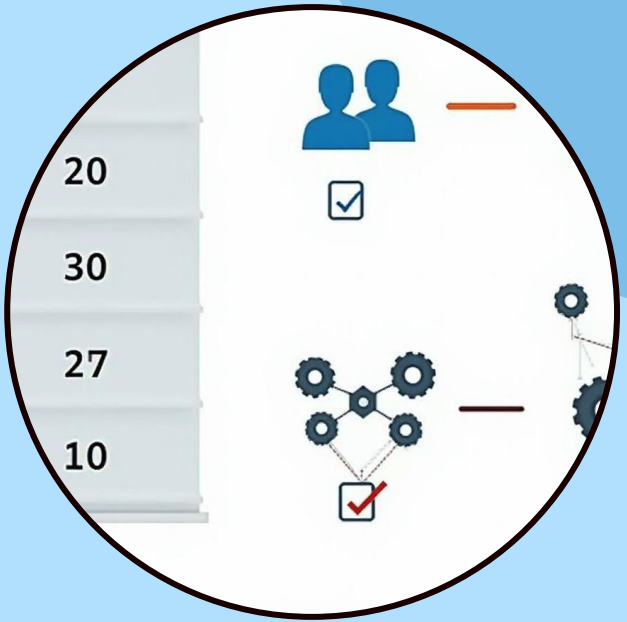

Análise de Variáveis

Seleção e remoção de variáveis

A variável *FBS over 120* foi removida por apresentar correlação muito baixa com o alvo. A variável *Cholesterol*, apesar da menor correlação entre as restantes (12%), foi mantida, pois modelos utilizados beneficiam-se da diversidade de variáveis para aumentar a precisão do modelo final.

Thallium mostrou a maior correlação (52%) com a presença de doença cardíaca. A análise das correlações foi determinante para a seleção das variáveis que compuseram o modelo preditivo, otimizando a capacidade de distinção entre pacientes com e sem doença.

Impacto das variáveis no modelo

A combinação das variáveis selecionadas influenciou diretamente a eficiência dos modelos preditivos. Variáveis com maior correlação, como *Thallium*, tiveram peso significativo. A inclusão de variáveis de menor correlação, como *Cholesterol*, contribuiu para a robustez do modelo, aproveitando a capacidade dos modelos em lidar com múltiplas fontes de informação.

Modelos de Aprendizado de Máquina

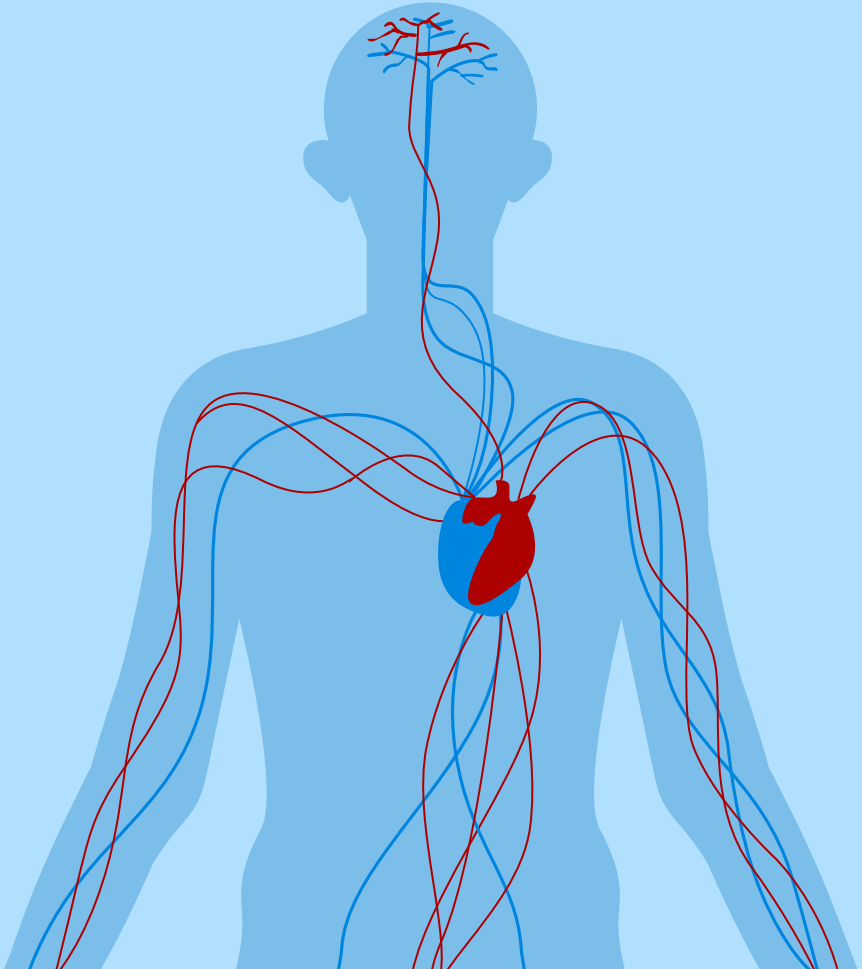

Técnicas de aprendizado de máquina utilizadas

Foram aplicados três modelos avançados de aprendizado de máquina: **Random Forest, SVM e XGBoost**. Random Forest e XGBoost são técnicas de *ensemble* que combinam múltiplos classificadores para melhorar o desempenho, enquanto o SVM é um modelo baseado em hiperplanos que busca maximizar a margem entre classes. Essas abordagens aumentam a precisão e a capacidade de generalização do modelo ao reduzir o risco de overfitting e capturar padrões complexos nos dados.

Ajuste de hiperparâmetros com GridSearch

O GridSearch foi fundamental para encontrar a melhor combinação de hiperparâmetros em cada modelo. Esse processo otimizou o desempenho, garantindo que os modelos funcionassem na sua capacidade máxima, ajustando parâmetros como o número de árvores e a profundidade dos modelos.

Avaliação de desempenho e comparação de modelos

A avaliação utilizou *cross-validation*, AUC e métricas do *classification_report* para uma análise completa. O modelo Random Forest destacou-se, alcançando AUC de 0,81 contra 0,77 (SVM) e 0,79 (XGBoost) e acurácia média de 0,88 contra 0,88 (SVM) e 0,86 (XGBoost), demonstrando maior robustez e confiabilidade em relação aos demais modelos testados.

Conclusões

O modelo Random Forest foi o mais eficaz para prever doença cardíaca, com desempenho consistente e alta acurácia. Aprimoramentos futuros podem incluir expansão da base de dados e incorporação de novas variáveis correlacionadas, visando otimizar ainda mais a capacidade preditiva e a aplicabilidade clínica do modelo.